

Grupo 11

luiza.pincitori@sou.unifeob.edu.br , Gustavo Henrique Fileni

Atividade do projeto de extensão do dia 18/08/2026 - Prof. Marcelo

AED / DevOps – Definição da fonte e fluxo de dados

Ideia inicial - Pesquisa e análise de Hardware

Nossa ideia inicial tem como o intuito de facilitar a pesquisa de hardware de usuários em quantidades massivas para análise, seja para o game development ou sizing de infraestrutura corporativa.

A ideia consiste em usar todos os conceitos desse módulo (Big Data, Probabilidade e Estatística, DevOps e Análise exploratória de dados) para gerar e armazenar esses dados de maneira consistente e uniforme, além de apresentar um dashboard personalizado via HTML e JS.

Situação - Problema

Tanto no ecossistema de desenvolvimento de jogos quanto no planejamento de infraestrutura corporativa (TI), a tomada de decisão sobre dimensionamento (sizing) e otimização de software costuma ser baseada em dados fragmentados, desatualizados ou em meras estimativas.

No Game Development: Desenvolvedores enfrentam altas taxas de reembolso, avaliações negativas e travamentos por não saberem a real capacidade computacional (RAM, VRAM, CPU) da sua base de jogadores.

Na Infraestrutura Corporativa: Equipes de TI realizam compras desnecessárias de equipamentos ou sofrem com degradação de performance por não possuírem visibilidade contínua sobre o perfil e gargalos do parque de máquinas dos colaboradores.

A ausência de uma plataforma centralizada e automatizada de coleta e análise massiva de hardware impede que empresas e desenvolvedores tomem decisões técnicas e financeiras orientadas a dados.

Variáveis

Aqui está um exemplo de dados necessários para armazenar as características de todo o estado operacional da máquina.

Nome da Variável	Tipo de Dado	Categoria	Descrição / Exemplo	Frequência de Geração
event_id	UUID / String	Identificação	Identificador único da medição (ex: c8a2f1b0-4a8b.. .)	Por evento gerado
system_id	UUID / String	Identificação	Identificador único e anônimo da máquina	Por evento gerado
timestamp	Datetime (ISO 8601)	Temporal	Data e hora da medição em UTC (ex: 2026-08-18T14:20:00Z)	Por evento gerado
os_name	Categorical / String	Sistema	Sistema Operacional (ex: "Windows", "Linux", "macOS")	Baixa (Apenas na inicialização/Mudança)
os_version	String	Sistema	Versão detalhada do SO (ex: "10.0.19045", "Ubuntu 22.04")	Baixa

cpu_model	String	Hardware (CPU)	Modelo comercial da CPU (ex: "Intel Core i5-12400F")	Estática (Apenas no cadastro)
cpu_cores_physical	Integer	Hardware (CPU)	Quantidade de núcleos físicos de processamento (ex: 6)	Estática
cpu_threads	Integer	Hardware (CPU)	Quantidade de núcleos lógicos / threads (ex: 12)	Estática
cpu_clock_base_ghz	Float	Hardware (CPU)	Frequência base da CPU em GHz (ex: 2.50)	Estática
cpu_usage_pct	Float	Telemetria/Uso	Percentual de uso instantâneo da CPU (ex: 45.8)	Alta (Ex: Coleta periódica a cada X min)
ram_total_gb	Float / Integer	Hardware (RAM)	Capacidade total de memória RAM física em GB (ex: 16.0)	Estática

ram_usage_pct	Float	Telemetria/Uso	Percentual de ocupação da memória RAM (ex: 68.2)	Alta (Periódica)
gpu_model	String	Hardware (GPU)	Modelo do processador gráfico (ex: "NVIDIA GeForce RTX 3060")	Estática
gpu_vram_total_gb	Float	Hardware (GPU)	Memória VRAM dedicada da GPU em GB (ex: 12.0)	Estática
gpu_vram_usage_pct	Float	Telemetria/Uso	Percentual de uso da memória VRAM (ex: 82.4)	Alta (Periódica)
storage_primary_type	Enum / String	Hardware (Disco)	Tecnologias de disco primário ("NVMe", "SATA_SSD", "HDD")	Estática
storage_free_gb	Float	Hardware (Disco)	Espaço livre disponível na partição principal em GB (ex: 142.5)	Média (Periódica)

display_resolution	String	Periférico	Resolução da tela principal (ex: "1920x1080", "2560x1440")	Baixa
--------------------	--------	------------	--	-------

Frequência de geração

Estáticos / Baixa Frequência: Gerados apenas no momento do registro da máquina ou quando ocorre alteração de periférico/SO (ex: cpu_model, ram_total_gb, os_name).

Dinâmicos / Alta Frequência: Métricas de consumo instantâneo capturadas periodicamente durante sessões de uso ou benchmarks (ex: cpu_usage_pct, ram_usage_pct, gpu_vram_usage_pct).

Média Frequência: Atributos que mudam ocasionalmente no tempo, como espaço livre em disco (storage_free_gb).

Inconsistências

Além de fatores como a troca do hardware pelos usuários, podemos realçar outras falhas:

Falta de padronização: O mesmo componente é reportado de formas diferentes (ex: "NVIDIA RTX 3060", "RTX 3060", "Nvidia GeForce RTX 3060"). Isso quebra agrupações e contagens.

Valores Nulos: Máquinas com vídeo integrado não possuem VRAM dedicada e enviam campos vazios (Null), o que trava cálculos matemáticos.

Erro de leitura: Falhas do sistema operacional que geram leituras surreais, como uso de RAM em 150%, uso de CPU em -1% ou memória total zerada.

Eventos Duplicados e Fora de Ordem: Lags ou conexões de rede que fazem o cliente enviar a mesma medição duas vezes ou fora de ordem cronológica.

Pipeline

1. Geração dos Dados

- Origem: Script Python leve em máquinas locais ou gerador sintético de Big Data.
- Métricas: CPU, GPU, RAM, Disco e Sistema Operacional.
- Formato: Encapsulamento em requisições HTTP em JSON.

2. Recebimento da Telemetria

- Mecanismo: Endpoint/serviço em Python rodando em container Docker.
- Ação: Recebe os pacotes JSON das máquinas e valida o formato básico do payload.

3. Tratamento e Transformação

- Padronização: Aplicação de Regex para uniformizar nomes de modelos de CPUs e GPUs.
- Imputação: Substituição de valores nulos (ex: atribuir 0 para VRAM em GPUs integradas).
- Validação: Descarte de outliers e leituras impossíveis (ex: uso de RAM fora da faixa de 0% a 100%).
- Desduplicação: Filtro de registros repetidos combinando system_id + timestamp.

4. Análise Estatística & Probabilidade

- Estatística Descritiva & EDA: Cálculo de médias, medianas, desvios padrão dos recursos de hardware.
- Modelagem & Probabilidade: Agrupamento por perfis de máquinas

5. Disponibilização & Dashboard HTML

- Front-end: Interface web construída em HTML5 e JavaScript (Chart.js / Plotly).

